

**LAPORAN DESKRIPSI PROJEK UAS
DATA MINING**

**SISTEM PERINGKASAN EKSTRAKTIF ULASAN FILM BERBASIS GRAF
SEMANTIK DENGAN INTEGRASI KLASIFIKASI SENTIMEN REAL-TIME**



**Disusun Oleh :
Kelompok : 7**

Moh. Sefry Auditya Izza Efendi	434231076
Helmi Said Hidayatulloh	434231080
Muhammad Alif Adiawan	434231051

**D4 – Teknik Informatika
Fakultas Vokasi
Universitas Airlangga
2026**

A. DESKRIPSI PROYEK

Proyek ini mengembangkan aplikasi web katalog film berbasis Streamlit untuk mengatasi penumpukan informasi (*information overload*) dari ulasan penonton. Sistem ini secara dinamis mengintegrasikan dua metode NLP:

- **Klasifikasi Sentimen Real-Time (Supervised Learning)**

Menggunakan algoritma Support Vector Machine (SVM) dengan *Linear Kernel* untuk langsung memprediksi polaritas ulasan baru (positif/negatif) yang dimasukkan pengguna lewat formulir web secara instan.

- **Peringkasan Ekstraktif Berbasis Graf (Unsupervised Learning)**

Menggunakan algoritma TextRank/WGRA untuk memetakan kalimat ulasan menjadi struktur graf (*node* dan *edge weight* berbasis *Cosine Similarity*). Sistem otomatis menyajikan 3 kalimat paling representatif dari masing-masing kelompok sentimen secara instan pada halaman detail film.

B. INPUT DAN OUTPUT SISTEM

2.1 INPUT SISTEM

a. Data Statis (Basis Data CSV):

- movies.csv (Tabel Induk): Berisi id_film (PK), nama_film, gambar, deskripsi, dan genre.
- reviews.csv (Tabel Anak): Berisi id_ulasan (PK), id_film (FK), teks ulasan (Bahasa Indonesia), dan label sentiment.

b. Data Dinamis (Interaksi Pengguna):

- Parameter id_film yang terkirim saat tombol "Lihat Detail" diklik pada katalog utama.
- Teks ulasan baru yang diketik pengguna pada formulir input di halaman detail web.

2.2 OUTPUT SISTEM

- **Metadata Film:** Tampilan poster visual, judul, genre, dan sinopsis lengkap dari film yang dipilih.
- **Dual-Box Summary Panel:** Dua kotak ringkasan di bagian atas halaman detail (kotak hijau untuk 3 poin kalimat ulasan positif terbaik, kotak merah untuk 3 poin kalimat ulasan negatif terbaik).
- **Notifikasi Hasil Sentimen:** Pengumuman visual instan (st.success / st.error) mengenai label sentimen hasil prediksi model SVM dari ulasan baru yang diinput.
- **Daftar Ulasan Mentah:** Panel ulasan asli di bagian bawah yang otomatis ter-update dan bertambah secara *real-time* setelah ulasan baru disimpan.

C. TAHAPAN PENYELESAIAN PROYEK



Alur penyelesaian proyek ini mengombinasikan metodologi segmentasi objek relasional (Gabriela Nathania et al., 2021) dan arsitektur peringkat graf semantik (Khan et al., 2020) yang dibagi menjadi 5 fase utama:

Tahap 1: Pengembangan Model Klasifikasi SVM (Supervised Pipeline)

1. Translasi Dataset: Menerjemahkan dataset IMDb Inggris ke Indonesia dengan Google Translator API (deep-translator).
2. Data Splitting: Membagi data menjadi *Data Training* (80%) dan *Data Testing* (20%).
3. Ekstraksi Fitur: Mengonversi teks ulasan menjadi representasi angka menggunakan TF-IDF Vectorizer.
4. Model Training: Melatih algoritma Support Vector Machine (SVM) dengan parameter kernel='linear' menggunakan data training dan fitur TF-IDF tersebut.
5. Evaluasi & Eksport: Mengevaluasi performa model (*Accuracy, Precision, Recall, F1-Score*) menggunakan data testing, lalu mengekspor objek model matang beserta vektorisernya menggunakan pustaka Joblib menjadi file biner model_svm.pkl dan vectorizer.pkl.

Tahap 2: Perancangan Basis Data Relasional

- Membuat data tiruan (*mock data*) lokal berskala kecil untuk representasi katalog film di halaman utama web.
- Memisahkan data ke dalam file movies.csv dan reviews.csv yang saling terhubung via *Foreign Key* (id_film) di dalam memori komputer melalui Pandas.

Tahap 3: Klasifikasi Real-Time pada Web (Runtime Phase)

- Memuat file biner *model_svm.pkl* dan *vectorizer.pkl* menggunakan fungsi `joblib.load()` ke dalam backend *framework* Streamlit dengan optimasi fungsi *cache* (`@st.cache_resource`).
- Mengalirkan input teks dari ulasan baru pengguna ke dalam fungsi `model.predict()` secara instan tepat setelah tombol kirim ditekan.

- Menangkap label prediksi sentimen (positive/negative), lalu menyimpan teks ulasan baru beserta label tersebut secara otomatis ke dalam database reviews.csv menggunakan fungsi Pandas `df.to_csv()`.

Tahap 4: Pra-pemrosesan & Graf Semantik Dinamis (Unsupervised Pipeline)

- Membaca ulang file reviews.csv terbaru yang telah diperbarui, lalu menyaring dan memisahkan ulasan aktif berdasarkan `id_film` yang sedang dibuka dan label sentimennya.
- Menjalankan pipa NLP bahasa Indonesia pada kalimat: *Sentence Segmentation* (NLTK), *Case Folding*, dan *Stopwords Removal* (mengeliminasi kata umum seperti "yang", "dan", "di").
- Mengonversi kumpulan kalimat hasil pra-pemrosesan ke bentuk TF-IDF baru, menghitung kedekatan makna via *Cosine Similarity* (kedekatan dipangkas untuk mencegah redundansi), dan membentuk objek graf tidak berarah menggunakan library NetworkX.

Tahap 5: Perangkingan Kalimat, Visualisasi, & Evaluasi Ringkasan

- Menjalankan algoritma TextRank/WGRA pada objek graf NetworkX hingga mencapai konvergensi untuk menghitung skor kepentingan relatif dari tiap kalimat berdasarkan bobot keterhubungannya.
- Mengekstrak 3 kalimat teratas dengan skor tertinggi dari masing-masing kelompok sentimen dan menampilkannya pada kotak ringkasan dual-box antarmuka Streamlit secara dinamis setelah memicu fungsi `st.rerun()`.
- Menguji kualitas performa hasil ringkasan sistem terhadap ringkasan manusia (*ground truth*) secara berkala menggunakan metrik standar ROUGE-1 dan ROUGE-2.

REFERENSI

1. Khan, A., et al. (2020). *Movie Review Summarization Using Supervised Learning and Graph-Based Ranking Algorithm*. (Referensi pemisahan sentimen biner dan perangkingan graf semantik).
2. Gabriela Nathania, et al. (2021). *Extractive Hotel Review Summarization based on TF/IDF and Adjective-Noun Pairing by Considering Annual Sentiment Trends*. *Procedia Computer Science*, 179, 558-565. (Referensi alur kerja penyaringan objek relasional dan pipa pra-pemrosesan teks).